

Actividad 4
Sistema inteligente de Clasificación documental Utilizando procesamiento
de lenguaje natural.

Estudiante: Luis Alberto lozano Alvarez

Docente: William Ruiz

Procesamiento de lenguaje natural

Corporación Universitaria Ibero Americana
Especialización en inteligencia Artificial
Mayo 2026
Tunja

TABLA DE CONTENIDO

Contenido

Resumen:	4
SUMMARY.....	6
Palabras claves :.....	7
Introducción	8
Objetivo general	9
Objetivos específicos.....	9
Materiales y métodos.....	10
Metodología de desarrollo	11
Herramientas y tecnologías utilizadas.	11
Procesamiento textual.	11
Representación vectorial TF-IDF.....	12
Entrenamiento del modelo.....	12
Interfaz grafica	14
Resultados.....	15
Métricas obtenidas.....	16
Matriz de confusión.....	17
Resultados de clasificación.	17

Discusión.	18
CONCLUSIONES	19
REFERENCIAS BIBLIOGRÁFICAS.....	20

Resumen:

Este proyecto tiene como objetivo principal poder desarrollar un sistema inteligente de clasificación documental en las cuales se utilizaron técnicas de procesamiento de lenguaje natural (PNL), minería de textos y algoritmos de Machine Learning, con el propósito de automatizar procesos organizacionales relacionados con la clasificación y gestión documental. En la situación tecnológica actual, muchas organizaciones realizan todavía la clasificación de documentos de manera manual, lo que genera problemas asociados a la pérdida de tiempo, errores humanos, baja eficiencia operativa y dificultades en la administración de grandes volúmenes de información textual, debido a esto, se crea la necesidad de implementar soluciones tecnológicas capaces de procesar automáticamente documentos digitales mediante inteligencia artificial.

Este sistema permite cargar documentos en formato Pdf y Word, igual que ingresar texto de manera manual, para posteriormente realizar procesos de limpieza textual, normalización y representación vectorial utilizando la técnica TF-IDF. posteriormente, los textos se procesan por modelos de Machine Learning, los cuales se entrenaron de manera previa para poder determinar de manera automática la categoría documental correspondiente, adicional se integró un Dashboard analítico que permita visualizar métricas y estadísticas con las clasificaciones realizadas.

Durante el desarrollo de este proyecto se han utilizado diferentes herramientas y librerías de Python, como Streamlit para la construcción de una interfaz gráfica, Scikit-learn para entrenamiento de modelos de Machine Learning, Pandas para el manejo de datos, Matplotlib y Seaborn para visualización de resultados, Wordcloud para la representación gráfica de palabras relevantes y PyPDF2 junto con Python-docx para la lectura automática de documentos.

Como parte del proceso metodológico, se implementan técnicas de procesamiento textual orientadas a mejorar la calidad de los datos, en estas técnicas se encuentran la limpieza de caracteres especiales, normalización de texto, tokenización y eliminación de palabras irrelevantes, posteriormente, se aplicó la representación TF-IDF para transformar los documentos en vectores numéricos adecuados para el entrenamiento de modelos supervisados.

En cuanto a los resultados obtenidos, el sistema logró calificar documentos de forma automática con altos niveles de precisión y estabilidad, lo cual permite evidenciar lo efectivo del procesamiento de lenguaje natural de procesos de organizaciones reales además se integró un módulo de inteligencia artificial explicable capaz de mostrar las palabras más relevantes detectadas por el modelo durante la clasificación, facilitando así la interpretación de resultados generados por el sistema.

Finalmente, el proyecto logró demostrar que las técnicas de minería de texto y PLN representan herramientas altamente útiles para automatizar procesos documentales dentro de las organizaciones y contribuyendo de manera significativa a la eficiencia administrativa, reducción de tiempos operativos y mejora en la gestión de la información.

SUMMARY

The main objective of this project was to develop an intelligent document classification system using Natural Language Processing (NLP), text mining, and Machine Learning algorithms, with the purpose of automating organizational processes related to document classification and management. Nowadays, many organizations still classify documents manually, which causes problems like wasted time, human errors, low operational efficiency, and difficulties managing large amounts of textual information. Because of this, there is a growing need to implement technological solutions capable of automatically processing digital documents through artificial intelligence.

The developed system allows users to upload PDF and Word documents, as well as manually enter text, in order to later perform text cleaning, normalization, and vector representation processes using the TF-IDF technique. After that, the texts are processed by previously trained Machine Learning models to automatically determine the corresponding document category. In addition, an analytical dashboard was integrated to visualize metrics and statistics related to the classifications made by the system.

During the development of the project, different Python tools and libraries were used, including Streamlit for building the graphical interface, Scikit-learn for training Machine Learning models, Pandas for data handling, Matplotlib and Seaborn for result visualization, WordCloud for graphical representation of relevant words, and PyPDF2 together with python-docx for automatic document reading.

As part of the methodological process, several text preprocessing techniques were implemented to improve data quality. These techniques included special character cleaning, text normalization, tokenization, and removal of irrelevant words. Later, the TF-IDF representation was applied to transform the documents into numerical vectors suitable for supervised model training.

Regarding the obtained results, the system was able to classify documents automatically with high levels of accuracy and stability, showing the effectiveness of Natural Language Processing in real organizational processes. Additionally, an explainable artificial intelligence module was integrated, capable of displaying the most relevant words detected by the model during classification, making it easier to understand the results generated by the system.

Finally, the project demonstrates that text mining and NLP techniques are highly useful tools for automating document processes inside organizations, significantly contributing to administrative efficiency, reduction of operational times, and improvement in information management.

Palabras claves :

- Procesamiento de lenguaje natural
- NLP
- Machine Learning
- TF-IDF
- Minería de texto
- Clasificación Documental

- Inteligencia Artificial
- Automatización de procesos

Introducción

La transformación digital ha permitido a las organizaciones modernas dependan bastante de sistemas informáticos para gestionar grandes cantidades de información documental. Bajo estos parámetros, la clasificación documental constituye un tarea fundamental para garantizar la organización, recuperación y administración eficiente de documentos dentro de diferentes áreas administrativas, jurídicas y académicas. Sin embargo, en múltiples organizaciones los procesos continúan realizándose de una manera manual, lo que genera manejo del tiempo ineficiente en los altos tiempos operativos, errores humanos y dificultades en el manejo eficiente de la información.

Bajo esta problemática, surge la necesidad de implementar herramientas tecnológicas que permiten automatizar la clasificación documental mediante el uso de inteligencia artificial y técnicas de procesamiento natural. El PNL constituye una rama de la inteligencia artificial enfocada en permitir que los computadores comprendan, interpreten y procesen lenguaje humano de manera automática.

El proyecto tiene como finalidad desarrollar un sistema inteligente de clasificación documental basado en técnicas de minería de texto, representación vectorial TF-IDF y modelos de Machine Learning supervisado. El sistema permite clasificar documentos de manera automática según su

contenido textual , lo cual integra funcionalidades de lectura automática de archivos Pdf y Word, Dashboard analítico y visualización de palabras relevantes y explicabilidad del modelo.

El proyecto fue fundamentado en diversos conceptos teóricos relacionados con minería de texto , clasificación automática y procesamiento documental. Según *Marin-Alvarez et al. (2020)*, las técnicas de representación semiautomática de modelo conceptuales han permitido estructurar información textual proveniente de documentos escritos en lenguaje natural. A su vez *Lezcano et al. (2015)*, destacan la importancia del procesamiento lingüístico para automatizar procesos relacionados con extracción y clasificación de la información .

Este proyecto también se justifica desde mi punto de vista profesional y organizacional, ya que nos permite reducir significativamente tiempos de clasificación, optimizar procesos administrativos y disminuir errores asociados a la Manipulación manual de documentos.

Objetivo general

Desarrollar un sistema inteligente de clasificación documental utilizando técnicas de procesamiento de lenguaje natural y machine learning.

Objetivos específicos

- Implementar técnicas de limpieza y preprocesamiento textual.

- Aplicar representación vectorial mediante TF-IDF.
- Entrenar modelos de Machine Learning para clasificación documental.
- Construir una interfaz gráfica utilizando Streamlit.
- Implementar módulos de visualización e inteligencia artificial explicable.



Materiales y métodos.

Metodología de desarrollo

Este proyecto fue desarrollado utilizando la metodología incremental, permitiendo construir un sistema por módulos independientes que posteriormente fueron integrados en una sola aplicación funcional .

Inicialmente se realizó la construcción del dataset documental, el cual contiene diferentes categorías de documentos utilizados para entrenar el modelo de clasificación. Posteriormente se implementaron procesos de limpieza textual y representación vectorial.

Herramientas y tecnologías utilizadas.

Herramienta	Función
Python	Lenguaje principal
Streamlit	Interfaz grafica
Scikit-learn	Machine learning
Pandas	Manipulacion de datos
Matplotlib	Visualización
Seaborn	Graficas estadísticas
Wordcloud	Nube de palabras
PyPDF2	Lectura PDF
Python-docx	Lectura Word

Procesamiento textual.

Se implementaron diferentes técnicas de procesamiento para mejorar la calidad del texto antes del entrenamiento del modelo.

Entre las técnicas utilizadas se encuentran:

- Conversión a minúsculas.
- Eliminación de caracteres especiales.
- Eliminación de signos de puntuación.
- Tokenización.
- Normalización textual.
- Eliminación de espacios innecesarios.

Estas técnicas permitieron mejorar la calidad semántica de los datos utilizados por el modelo.

Representación vectorial TF-IDF

La técnica TF-IDF fue utilizada para convertir los textos en vectores numéricos interpretables por los modelos de Machine learning.

```

$$TF\text{-}IDF(t,d)=TF(t,d)\times \log\left(\frac{N}{DF(t)}\right)$$

```


TF-IDF permitió identificar las palabras más relevantes dentro de cada documento, asignando mayor peso a términos significativos.

Entrenamiento del modelo

El sistema se entrenó utilizando algoritmos supervisados de clasificación documental, entre los modelos que se evaluaron está:

- Logistic Regression
- Random Forest
- Naive Bayes
- Support Vector Machine (SVM)

De manera posterior, se seleccionó automáticamente el modelo con mejor desempeño según métricas de accuracy.



Interfaz grafica .

La interfaz grafica fue desarrollada utilizando Streamlit, permitiendo:

- Cargar archivos PDF y Word.
- Ingresar texto manualmente.
- Visualizar categorías predichas.
- Mostrar probabilidades.
- Visualizar Dashboard analítico.
- Mostrar Wordcloud.
- Mostrar explicabilidad del modelo.

Figura 2. Interfaz principal del sistema




Figura 4. Explicación de IA (Palabras clave)



Figura 3. Dashboard analítico



Figura 5. WordCloud NLP



Resultados

Los resultados obtenidos durante el desarrollo de este proyecto permiten evidenciar que las técnicas de procesamiento de lenguaje natural aplicadas a la clasificación documental permiten automatizar procesos organizacionales de forma eficiente.

El sistema logró clasificar documentos automáticamente utilizando modelos de machine learning supervisado. Las métricas obtenidas muestran un


comportamiento estable del modelo y una adecuada capacidad de generalización.

Métricas obtenidas.

Las principales métricas evaluadas fueron :


- Accuracy
- Precision
- Recall
- F1-score

Estas métricas permitieron validar el desempeño del modelo durante las pruebas realizadas.



Matriz de confusión

La matriz de confusión permitió visualizar el comportamiento de las predicciones realizadas por el sistema.



Resultados de clasificación.

El sistema logro identificar correctamente categorías documentales relacionadas con documentos administrativos , jurídicos y académicos, a su vez , el módulo

de inteligencia artificial explicable permitió identificar las palabras mas relevantes detectadas durante la clasificación, incrementando la interpretabilidad del sistema.

El Dashboard analítico permite visualizar estadísticas relacionadas con clasificaciones realizadas y generar reportes exportables.

Discusión.

Los resultados que se obtuvieron demuestran que el uso de técnicas de procesamiento de lenguaje natural representan una excelente alternativa para automatizar procesos documentales dentro de las organizaciones.

La implementación de TF-IDF permitió representar adecuadamente la información textual, facilitando el entrenamiento de modelos supervisados capaces de identificar patrones lingüísticos dentro de los documentos.

De manera adicional, la integración de modelos de machine learning permitió reducir significativamente la intervención manual de tareas de clasificación documental.

Uno de los principales aportes de este proyecto corresponde a la integración de módulos de explicabilidad e interfaces visuales, los cuales facilitan la comprensión de las decisiones tomadas por el modelo.

Sin embargo, también se identifican limitaciones relacionadas con el tamaño del dataset y la diversidad documental utilizada durante el entrenamiento. En

futuras versiones del sistema se recomienda ampliar el conjunto de datos e incorporar modelos avanzados basados en redes neuronales y transformes.

CONCLUSIONES

- El procesamiento de lenguaje natural permitió automatizar satisfactoriamente la clasificación documental.
- La técnica TF-IDF logro representar adecuadamente la información textual utilizada durante el entrenamiento.
- Los modelos de machine learning mostraron un comportamiento estable y eficiente para tareas de clasificación documental.
- La interfaz desarrollada en Streamlit permitió construir una aplicación funcional, intuitiva y visualmente amigable.
- El módulo de inteligencia artificial explicable facilito la interpretación de los resultados generados por el sistema.
- El proyecto demuestra el potencial del PLN dentro de procesos organizacionales relacionados con gestión documental.
- Link web: <http://localhost:8501>

REFERENCIAS BIBLIOGRÁFICAS

Marín-Alvarez, D., Manrique-Losada, B., & Bernardo Quintero, J. (2020).

Método para la representación semi-automática de modelos conceptuales desde documentos de negocio escritos en lenguaje natural en español. INGENIARE - Revista Chilena de Ingeniería, 28(4), 565–584.

Lezcano R., L. A., Guzmán L., J. A., & Gómez A., S. A. (2015). Extraction of goals and their classification in the KAOS model using natural language processing. INGENIARE - Revista Chilena de Ingeniería, 23(1), 59–66.

Niño Zambrano, M. A., López Gómez, I. D., Andrade, C., Cobos Lozada, C. A., & Fabregat Gesa, R. (2012). Modelo Semántica de Expansión

de Consultas para la Búsqueda Web (MSEC). UIS Ingenierías, 11(1), 11–20.

Rodríguez, T., & Aguilar, J. (2017). Implementación del Marco Ontológico Dinámico Semántico. INGENIARE - Revista Chilena de Ingeniería, 25(3), 430–448.

Scikit-learn Developers. (2025). Scikit-learn Documentation.

Streamlit Developers. (2025). Streamlit Documentation.

